

---

# Klasyfikator ruchów czujnika IMU na podstawie rekurencyjnej sieci neuronowej

---

**Mateusz Woźniak**

wozniakmat@student.agh.edu.pl

**Maciej Pawłowski**

maciekp@student.agh.edu.pl

## 1 Abstrakt

Przedmiotem tego artykułu jest omówienie realizacji zadania klasyfikacji ruchów z urządzenia IMU (Inertial Measurement Unit). Czujnik IMU określa przyspieszenia postępowe i kątowe używając żyroskopu, akcelerometru i magnetometru. IMU jest powszechnie stosowane w lotnictwie, robotyce, wirtualnej rzeczywistości i medycynie. W lotnictwie umożliwia precyzyjne sterowanie statkami powietrznymi, a w robotyce wspomaga autonomiczne poruszanie się robotów. Jednym z zastosowań klasyfikatora ruchów może być detekcja przeciągnięcia samolotu. Z kolei w motoryzacji, IMU znajduje użycie w systemach kontroli stabilności pojazdów oraz w zaawansowanych systemach wspomagania kierowcy, które poprawiają bezpieczeństwo. My chcemy zaproponować realizację klasyfikatora 5 z góry ustalonych ruchów używając rekurencyjną sieć neuronową.

## 2 Zbiór danych


Dane zostały zebrane z urządzenia Samsung Galaxy S10e 2019. Każdy ruch został zebrany ręcznie a seria danych z czujników była zapisywana do pliku *csv* o ilości wierszy takiej jak ilość kroków czasowych. Interwał samplowania pomiaru z czujnika ustaliliśmy na  $50ms$ . To znaczy, że w ciągu każdej sekundy trwania ruchu następowało 20 odczytów.

Ruchy były wykonywane przy włączonej aplikacji mobilnej napisanej w Kotlinie (rys. 1).

Dane były wysyłane na zdalny serwer na którym był uruchomiony mikroserwis HTTP napisany w Go. Mikroserwis zbierał dane i zapisywał je na dysk. Dzięki temu zbieranie danych odbywało się sprawnie, a mikroserwis dawał nam informacje o ilości ruchów dla każdej z klas.

Przykładowy plik *csv*:

```
gyro_x;gyro_y;gyro_z;magnetometer_x;...  
-0.062384613;-0.15294538;-0.32650748;-43.62;...  
-0.87361366;0.41210496;-0.49510628;-43.5;...  
-1.7758616;0.20685424;-1.4266758;-43.92;...  
-1.8662697;-0.46876273;-1.4040737;-44.399998;...  
-0.7575493;-0.8077929;-1.488984;-44.28;...  
0.06895141;-1.5170075;-2.1273382;-46.14;...
```



Rysunek 1: Aplikacja mobilna do zbierania danych z czujnika IMU

Zebraliśmy dane dla następujących klas:

Klasa	Opis ruchu	Ilość sampli
SQUARE	Ruch imitujący rysowanie kwadratu	203
TRIANGLE	Ruch imitujący rysowanie trójkąta	179
CIRCLES_LEFT	Rysowanie okręgu przeciwnie z ruchem wskazówek zegara	193
CIRCLES_RIGHT	Rysowanie okręgu zgodnie z ruchem wskazówek zegara	191
FORWARD_BACK	Ruch "od siebie - do siebie"	187

Dane zostały załadowane do tensora o kształcie  $(B, T, C)$ , gdzie

- $B$  - wsad
- $T$  - oś czasu
- $C$  - cechy (3, ponieważ odrzuciliśmy pomiary z magnetometru i żyroskopu)

W przypadku, gdy sample były różnej długości, tensor został dopełniony zerami, by  $T$  było równe 100. Dzięki temu tensor stawał się jednorodny [4].

### 3 Model

Ze względu na to, że zadanie klasyfikacji ruchów ma być niezależne od czasu, tzn. że ruch może zawierać dowolną ilość sampli zdecydowaliśmy się użyć rekurencyjnej sieci neuronowej z komórką LSTM. Long Short-Term Memory (LSTM) to rodzaj architektury sieci neuronowej rekurencyjnej (RNN), zaprojektowanej w celu przezwyciężenia ograniczeń tradycyjnych RNN w przechwytywaniu i uczeniu się długoterminowych zależności w danych sekwencyjnych. LSTMy zostały wprowadzone przez Seppa Hochreitera i Jürgena

Schmidhubera w 1997 roku [1]. Chcemy, aby sieć neuronowa nauczyła się zależności w czasie pomiędzy zmianami w przyspieszeniach czujnika [2][3]. W związku z tym w pierwszym podejściu zdecydowaliśmy sprawdzić architekturę składającą się z 32 komórek LSTM oraz dwóch warstw gęstych o wielkości 24 i 5. Na ostatniej warstwie została zastosowana funkcja aktywacji *softmax* by uzyskać dystrybucję prawdopodobieństwa klas (realizuje to *CrossEntropyLoss*)

Po kilku próbach znaleźliśmy hiperparametry modelu, które dają najlepsze zachowanie sieci. LSTM musi mieć 22 komórki, a warstwa gęsta musi mieć 32 neurony. Przeszukiwanie przestrzeni hiperparametrów zostało zrealizowane metodyką gridsearch. Finalny model ma następującą architekturę:


```
import torch
import torch.nn as nn

class Net(nn.Module):
    def __init__(self, input_size):
        super(Net, self).__init__()
        self.lstm = nn.LSTM(input_size, 22, batch_first=True)
        self.fc1 = nn.Linear(22, 32)
        self.fc2 = nn.Linear(32, 5)

    def forward(self, x):
        _, (h_n, _) = self.lstm(x)
        x = h_n[-1, :, :]
        x = self.fc1(x)
        x = self.fc2(x)
        return x
```


## 4 Obserwacje

Model osiąga zbieżność dostarczając przy tym jakościowe predykcje. Zadanie znajdowania zależności między odczytami daleko od siebie nie jest trywialne, aczkolwiek optymalizator jest w stanie znaleźć odpowiedni kierunek by dostosować wagi sieci (rys. 2).



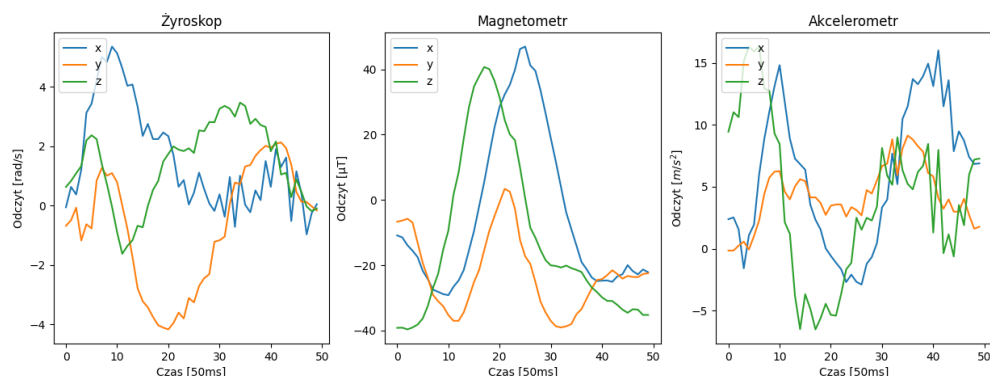
Rysunek 2: Wykres funkcji straty

Użyty optymalizator to *Adam* ze współczynnikiem uczenia 0.001 Uzyskana precyzja to ok. 90% (rys. 3). Warto zaznaczyć, że aby osiągnąć takie wyniki musieliśmy uprościć ilość cech do 3, wybierając dane jedynie z żyroskopu. Użycie innych cech powodowało spadki jakości predykcji.



Rysunek 3: Wykres precyzji na zbiorze walidacyjnym

Co więcej, dostrzeżliśmy różnice w zakresach odczytów używając kilku czujników IMU. Pomiary znacząco różniły się od siebie pomiędzy markami i modelami smartfonów. Przykładowy odczyt na rys. 4. W związku z tym całe badanie oparliśmy na jednym urządzeniu Samsung Galaxy S10e.



Rysunek 4: Przykładowy odczyt ruchu dla klasy CIRCLES\_RIGHT

## 5 Inferencja

Ze względu na to, że inferencja na smartfonie w przypadku rekurencyjnych sieci neuronowych jest trudna, zdecydowaliśmy się uruchomić zdalny serwer predykcji. Zastosowaliśmy iteracyjną metodologię prac nad projektem:

1. Wytrenuj model na lokalnym sprzęcie (laptop).
2. Zbuduj obraz Dockera z wagami zawartymi w środku i wypchnij go do rejestru
3. Na serwerze zdalnym: ściągnij obraz i uruchom serwer Flask

Dzięki temu byliśmy w stanie szybko ewaluować jakość modelu. Aplikacja mobilna wykonuje żądanie HTTP POST do serwera inferencji, by ten zwrócił wyniki.

## 6 Wnioski

Na podstawie metryk modelu można stwierdzić, że decyzja o wykorzystaniu rekurencyjnej sieci neuronowej była trafna. Zaproponowana sieć neuronowa cechuje się wysoką skutecznością w zadaniu klasyfikacji ruchów z urządzenia IMU.

## 7 Sprzęt

Do pomiarów wykorzystaliśmy smartfon Samsung Galaxy S10e 2019 wyposażony w czujnik IMU. Implementację modelu wykonaliśmy we frameworku PyTorch. Trening sieci neuronowej była wykonywany na Apple Macbook M1 16GB.

## Literatura

- [1] Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. *Neural Comput.* 9, 8 (1997), 1735–1780.
- [2] Rivera, Patricio, et al. "Recognition of human hand activities based on a single wrist imu using recurrent neural networks." *Int. J. Pharma Med. Biol. Sci.* 6.4 (2017): 114-118.

- [3] Ashry, Sara, Reda Elbasiony, and Walid Gomaa. "An LSTM-based descriptor for human activities recognition using IMU sensors." *Proceedings of the 15th International Conference on Informatics in Control, Automation and Robotics, ICINCO*. Vol. 1. 2018.
- [4] Staudemeyer, Ralf C., and Eric Rothstein Morris. "Understanding LSTM—a tutorial into long short-term memory recurrent neural networks." (2019).